

TP3 – Deep Learning

Redes Neurais do Zero com Interpretabilidade

Prof. Anderson Rocha

Deadline: 02/Junho/2026

Regra Geral

Façam **simples**, mas façam **do zero**.

Objetivo Geral

Desenvolver um modelo de rede neural artificial do zero, compreendendo o processo de aprendizado via backpropagation, e incorporar técnicas de interpretabilidade para analisar as decisões do modelo.

Requisitos Obrigatórios

Todos os grupos devem implementar, **do zero**:

- Forward pass;
- Backpropagation;
- Atualização de pesos via gradiente descendente (mini-batch);
- Funções de ativação:
 - ReLU (camadas escondidas);
 - Softmax (saída);
- Função de custo: **cross-entropy**.

Observação: Não é permitido utilizar bibliotecas de deep learning (PyTorch, TensorFlow, etc.) para a implementação do modelo. Bibliotecas auxiliares (NumPy, visualização, etc.) são permitidas.

Treinamento e Avaliação

- Utilizar mini-batch gradient descent;
- Apresentar curvas de:
 - Loss (treino);
 - Acurácia (treino/teste);
- Avaliar impacto de:
 - Taxa de aprendizado (α);
 - Tamanho do batch;
 - Arquitetura da rede (número de neurônios/camadas).

Interpretabilidade (Obrigatório)

Os grupos devem analisar e explicar as decisões do modelo.

Para cada aplicação, o grupo deve:

- Identificar quais entradas mais influenciam a decisão;
- Explicar decisões individuais do modelo;
- Utilizar pelo menos uma técnica de análise (ex: gradientes, perturbação, ablação).

Aplicações

Cada grupo será responsável por **uma das aplicações abaixo**.

Aplicação 1 – Classificação Tabular

Dataset: Breast Cancer Wisconsin

- Link: https://scikit-learn.org/stable/datasets/toy_dataset.html#breast-cancer-dataset

Objetivos:

- Treinar a MLP para classificação;
- Analisar a importância das features;
- Explicar decisões do modelo com base nas entradas.

Aplicação 2 – Dataset Sintético (2D)

Dataset: Two Moons / Circles

- Link: https://scikit-learn.org/stable/datasets/sample_generators.html

Objetivos:

- Treinar a MLP em dados não linearmente separáveis;
- Visualizar a fronteira de decisão;
- Interpretar como a rede separa as classes.

Aplicação 3 – Dataset com Potencial de Viés

Dataset: Adult Income (UCI)

- Link: <https://archive.ics.uci.edu/ml/datasets/adult>

Objetivos:

- Treinar modelo para predição de renda;
- Identificar possíveis vieses nas decisões;
- Propor e avaliar estratégias simples de mitigação.

Entrega

- Dessa vez, a entrega deve ter o Código-fonte completo, em notebook Python;
- Relatório (aprox. 5/6 páginas) contendo:
 - Descrição da implementação;
 - Experimentos realizados;
 - Resultados obtidos;
 - Análise de interpretabilidade;
 - Discussão crítica.

Critérios de Avaliação

- Qualidade dos experimentos;
- Profundidade da análise;
- Clareza na explicação das decisões do modelo;
- Organização do relatório e do código.

Extras (Opcional)

- Inicialização avançada (He/Xavier);
- Momentum;
- Comparação com implementação em framework;
- Técnicas adicionais de interpretabilidade.

Distribuição dos Temas

A distribuição das aplicações será realizada com base na média dos RAs dos integrantes de cada grupo.

Regra de Atribuição

- Calcular a média dos RAs do grupo;
- Considerar a parte inteira M ;
- A aplicação será definida por $M \bmod 3$:
 - Resto 0 $\rightarrow$ Aplicação 1;
 - Resto 1 $\rightarrow$ Aplicação 2;
 - Resto 2 $\rightarrow$ Aplicação 3;